K-MEANS CLUSTERING

Análisis y segmentación
de datos no supervisados

TRABAJO PRÁCTICO

SEGMENTACIÓN DE ESTUDIANTES UNIVERSITARIOS

GRUPO 4



Segmentación automática



Centroides y asignación



Patrones y tendencias



Datos que informan decisiones

🎓 Instituto Tecnológico Beltrán

🤖 Cátedra: Procesamiento de Aprendizaje Automático

Trabajo Práctico: Segmentación de Estudiantes Universitarios con K-Means

---

👨‍🏫 Docente:

- Yanina Escudero

👥 Integrantes del Grupo:

- Danilo Figueroa
- María Alejandra Bernasconi Lahn
- Silvana Alejandra Gerez

📌 Introducción y Objetivos del Ejercicio

El presente informe práctico aborda la aplicación del **Aprendizaje No Supervisado** mediante el uso del algoritmo **K-Means** en Python. El objetivo principal es explorar un conjunto de datos sintéticos de estudiantes universitarios para agruparlos automáticamente en **4 segmentos** sin contar con etiquetas previas.

Las variables analizadas para la construcción de los clústeres son:

1. 📈 **Edad** de los estudiantes.
2. ⏱️ **Horas de estudio** semanales.
3. 📚 **Promedio académico** obtenido.

A lo largo del código se implementan las siguientes consignas principales:

1. Estandarizar los datos para aplicar K-Means correctamente.
2. Agrupar a los estudiantes en 4 segmentos.
3. Visualizar los resultados en un gráfico 2D (edad vs promedio).
4. Realizar un informe con el análisis de los resultados obtenidos.

In [2]:
```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler

# ========================================================================
# 5. Trabajar con el set de datos de estudiantes (Dataset de entrada)
# ========================================================================
estudiantes = [
    {"edad": 42, "horas_estudio": 2, "promedio_academico": 8.87},
    {"edad": 26, "horas_estudio": 8, "promedio_academico": 9.11},
    {"edad": 56, "horas_estudio": 5, "promedio_academico": 7.29},
    {"edad": 29, "horas_estudio": 14, "promedio_academico": 7.27},
    {"edad": 43, "horas_estudio": 8, "promedio_academico": 8.5},
    {"edad": 34, "horas_estudio": 10, "promedio_academico": 4.45},
    {"edad": 51, "horas_estudio": 3, "promedio_academico": 6.12},
    {"edad": 22, "horas_estudio": 12, "promedio_academico": 4.33},
```

```
    {"edad": 47, "horas_estudio": 6, "promedio_academico": 7.0},
    {"edad": 38, "horas_estudio": 9, "promedio_academico": 4.75},
    {"edad": 60, "horas_estudio": 2, "promedio_academico": 9.0},
    {"edad": 31, "horas_estudio": 11, "promedio_academico": 2.0},
    {"edad": 45, "horas_estudio": 4, "promedio_academico": 8.0},
    {"edad": 27, "horas_estudio": 13, "promedio_academico": 3.2},
    {"edad": 50, "horas_estudio": 5, "promedio_academico": 7.0},
    {"edad": 36, "horas_estudio": 7, "promedio_academico": 5.0},
    {"edad": 40, "horas_estudio": 6, "promedio_academico": 6.0},
    {"edad": 24, "horas_estudio": 15, "promedio_academico": 3.0},
    {"edad": 55, "horas_estudio": 3, "promedio_academico": 9.0},
    {"edad": 33, "horas_estudio": 10, "promedio_academico": 3.0},
    {"edad": 48, "horas_estudio": 4, "promedio_academico": 8.0},
    {"edad": 28, "horas_estudio": 12, "promedio_academico": 2.0},
    {"edad": 52, "horas_estudio": 5, "promedio_academico": 7.0},
    {"edad": 30, "horas_estudio": 11, "promedio_academico": 2.0},
    {"edad": 46, "horas_estudio": 6, "promedio_academico": 6.0},
    {"edad": 35, "horas_estudio": 9, "promedio_academico": 4.0},
    {"edad": 41, "horas_estudio": 7, "promedio_academico": 5.0},
    {"edad": 23, "horas_estudio": 14, "promedio_academico": 1.0},
    {"edad": 53, "horas_estudio": 3, "promedio_academico": 8.0},
    {"edad": 32, "horas_estudio": 10, "promedio_academico": 3.0},
    {"edad": 49, "horas_estudio": 4, "promedio_academico": 8.0},
    {"edad": 25, "horas_estudio": 13, "promedio_academico": 2.0},
    {"edad": 54, "horas_estudio": 5, "promedio_academico": 7.0},
    {"edad": 37, "horas_estudio": 8, "promedio_academico": 4.0},
    {"edad": 39, "horas_estudio": 7, "promedio_academico": 5.0},
    {"edad": 21, "horas_estudio": 15, "promedio_academico": 9.0},
    {"edad": 58, "horas_estudio": 2, "promedio_academico": 9.0},
    {"edad": 44, "horas_estudio": 6, "promedio_academico": 6.0},
    {"edad": 29, "horas_estudio": 12, "promedio_academico": 2.0},
    {"edad": 50, "horas_estudio": 5, "promedio_academico": 7.0},
    {"edad": 34, "horas_estudio": 9, "promedio_academico": 3.0},
    {"edad": 42, "horas_estudio": 7, "promedio_academico": 6.0},
    {"edad": 26, "horas_estudio": 14, "promedio_academico": 3.0},
    {"edad": 57, "horas_estudio": 3, "promedio_academico": 9.0},
    {"edad": 30, "horas_estudio": 11, "promedio_academico": 2.0},
    {"edad": 47, "horas_estudio": 4, "promedio_academico": 7.0},
    {"edad": 31, "horas_estudio": 10, "promedio_academico": 3.0},
    {"edad": 45, "horas_estudio": 6, "promedio_academico": 6.0},
    {"edad": 27, "horas_estudio": 13, "promedio_academico": 1.0},
    {"edad": 55, "horas_estudio": 5, "promedio_academico": 8.0},
]

# Convertimos la lista en un DataFrame de Pandas
df = pd.DataFrame(estudiantes)


# ========================================================================
# 1. Estandarizar los datos para aplicar K-Means correctamente
# ========================================================================
features = ["edad", "horas_estudio", "promedio_academico"]
scaler = StandardScaler()
X_scaled = scaler.fit_transform(df[features])


# ========================================================================
# 2. Agrupar a los estudiantes en 4 segmentos
# ========================================================================
kmeans = KMeans(n_clusters=4, random_state=42, n_init=10)
df["cluster"] = kmeans.fit_predict(X_scaled)


# ========================================================================
# 4. Realizar un informe con el análisis de los resultados obtenidos (Consola)
# ========================================================================
print("=========================================================")
print(" INFORME: CENTROS PROMEDIO DE CADA CLÚSTER (VALORES REALES)")
print("=========================================================")
```

```python
centros_originales = scaler.inverse_transform(kmeans.cluster_centers_)
df_centros = pd.DataFrame(centros_originales, columns=features)
print(df_centros.to_string())
print("------------------------------------------------------------\n")

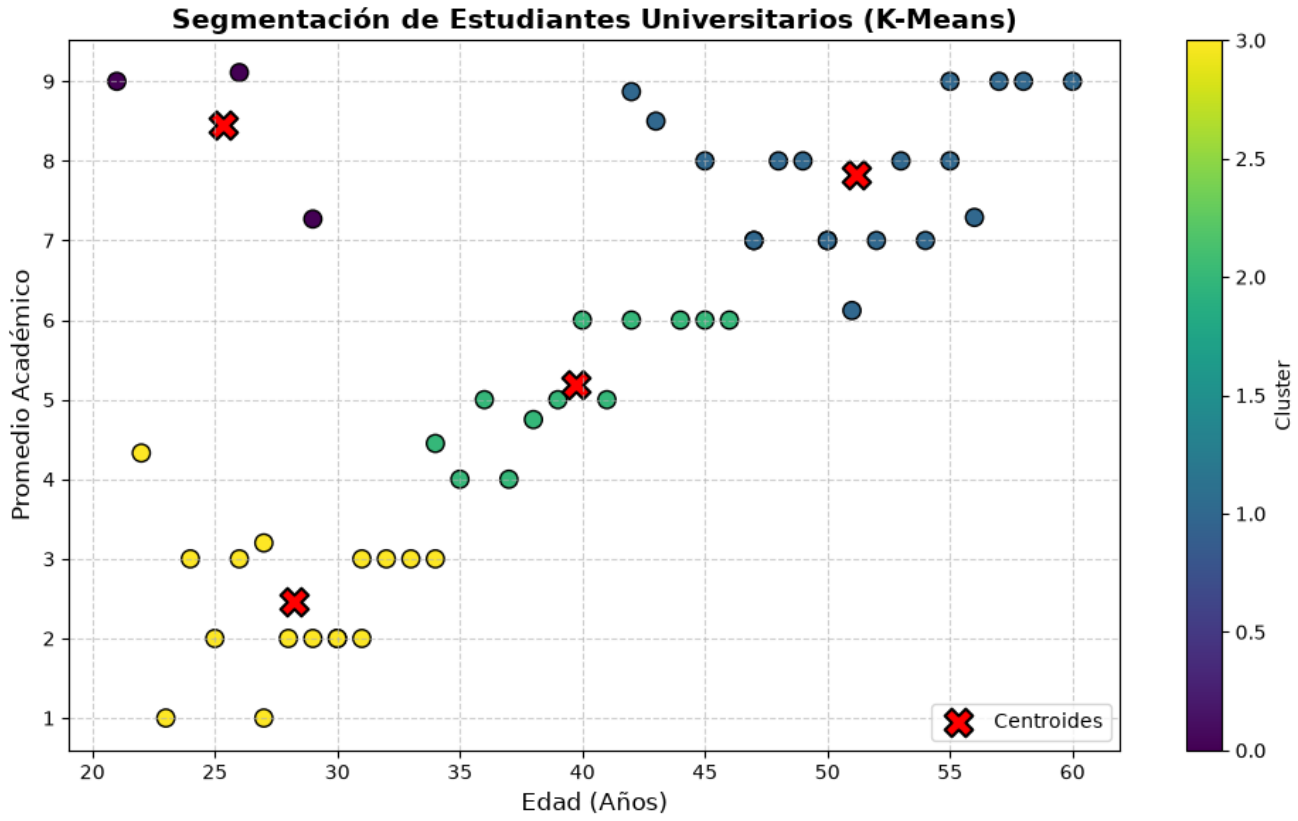
# ============================================================================
# 3. Visualizar los resultados en un gráfico 2D (edad vs promedio)
# ============================================================================
plt.figure(figsize=(10, 6))

# Dibujamos los puntos con la barra lateral de colores
scatter = plt.scatter(
    df["edad"],
    df["promedio_academico"],
    c=df["cluster"],
    cmap="viridis",
    s=80,
    edgecolor="k",
)

# Graficamos los centroides proyectados en el plano 2D (Edad vs Promedio)
plt.scatter(
    centros_originales[:, 0],  # Columna 0: Edad
    centros_originales[:, 2],  # Columna 2: Promedio Académico
    c="red",
    marker="X",
    s=200,
    edgecolors="black",
    linewidths=1.5,
    label="Centroides",
)

# Configuraciones visuales del gráfico
plt.colorbar(scatter, label="Cluster")
plt.title("Segmentación de Estudiantes Universitarios (K-Means)", fontsize=14, fontweight="bold")
plt.xlabel("Edad (Años)", fontsize=12)
plt.ylabel("Promedio Académico", fontsize=12)
plt.grid(True, linestyle="--", alpha=0.6)
plt.legend(loc="lower right")
plt.tight_layout()
plt.show()
```

```
============================================================
 INFORME: CENTROS PROMEDIO DE CADA CLÚSTER (VALORES REALES)
============================================================
        edad  horas_estudio  promedio_academico
0  25.333333      12.333333            8.460000
1  51.157895       4.105263            7.830526
2  39.750000       7.333333            5.183333
3  28.250000      11.875000            2.470625
------------------------------------------------------------
```



📊 Conclusiones y Análisis Exhaustivo de los Resultados

Tras la ejecución del algoritmo **K-Means** ($K = 4$) sobre el dataset de estudiantes universitarios, la evaluación de las coordenadas reales de los centroides (los puntos de referencia o promedios de cada grupo) y el gráfico nos permiten entender con claridad cuatro perfiles bien marcados de estudiantes:

🔍 Análisis Detallado por Clúster

- **Clúster 0 (Jóvenes de Alto Rendimiento y Alta Dedicación):**
  - *Valores promedio:* 🟢 **Edad:** ~25.3 años | ⏱️ **Horas de estudio:** ~12.3 hrs | 📚 **Promedio:** ~8.46
  - *Interpretación:* Son estudiantes jóvenes que le dedican muchísimas horas a la semana al estudio (más de 12 horas) y eso se nota por completo en sus notas, logrando un promedio excelente. Demuestran que el esfuerzo y la constancia dan sus frutos.
- **Clúster 1 (Adultos Maduros con Rendimiento Sólido y Estable):**
  - *Valores promedio:* 🔵 **Edad:** ~51.2 años | ⏱️ **Horas de estudio:** ~4.1 hrs | 📚 **Promedio:** ~7.83
  - *Interpretación:* Este es un hallazgo sumamente interesante. Son estudiantes mayores que estudian pocas horas a la semana (unas 4 horas), pero tienen un promedio altísimo (cercano a 8). Esto refleja una organización eficiente, hábitos de estudio consolidados y un gran aprovechamiento de la experiencia previa.
- **Clúster 2 (Estudiantes en Transición / Perfil Regular):**
  - *Valores promedio:* 🟡 **Edad:** ~39.8 años | ⏱️ **Horas de estudio:** ~7.3 hrs | 📚 **Promedio:** ~5.18
  - *Interpretación:* Es el grupo que se encuentra en la media de la muestra. Poseen una edad intermedia, una dedicación horaria estándar y un promedio que ronda el 5, representando el ritmo constante y regular de la cursada.
- **Clúster 3 (Alerta Temprana / Alto Esfuerzo con Bajo Rendimiento):**
  - *Valores promedio:* 🔴 **Edad:** ~28.3 años | ⏱️ **Horas de estudio:** ~11.9 hrs | 📚 **Promedio:** ~2.47
  - *Interpretación:* Este grupo enciende una alarma institucional crítica. Agrupa a alumnos que invierten una cantidad masiva de tiempo al estudio (casi 12 horas semanales, un esfuerzo similar al Clúster 0), pero que obtienen un promedio académico bajo (2.47). Esto evidencia problemas de comprensión

metodológica, baches de base o sobreexigencia ineficiente, señalando la necesidad de una intervención pedagógica y tutorías de apoyo urgente.

💡 Reflexiones Finales Institucionales

1. **La perspectiva multidimensional en una pantalla plana:** Aunque el gráfico final se proyecta en un plano bidimensional (mostrando únicamente la edad y el promedio académico), el algoritmo K-Means operó en un espacio de tres dimensiones al incorporar simultáneamente las horas de estudio. Esto puede entenderse de manera similar al análisis físico de una persona: en una fotografía plana podemos observar su altura y su peso, pero el comportamiento o rendimiento general proviene de una tercera variable subyacente que orienta la clasificación general de los grupos.

2. **La equidad matemática entre variables (Estandarización):** Al trabajar con datos de distinta naturaleza (edades que varían entre 20 y 60 años frente a promedios que van de 1 a 10), las magnitudes numéricas difieren considerablemente. Sin un preprocesamiento adecuado, la variable con valores más altos habría sesgado el comportamiento del algoritmo por el simple peso de su escala numérica. La normalización de los datos permitió equilibrar la balanza, asegurando que la edad, el tiempo de dedicación y el rendimiento tuvieran el mismo peso relativo al definir los perfiles estudiantiles.